

POLITECHNIKA WARSZAWSKA

WYDZIAŁ ELEKTRONIKI I TECHNIK INFORMACYJNYCH

WPROWADZENIE DO SZTUCZNEJ INTELIGENCJI

Perceptron wielowarstwowy

Autor:

Mateusz CHMURZYŃSKI 304021

16 maja 2025

Spis treści

1	Wstęp	2
2	Opis implementowanych algorytmów	2
3	Eksperymenty numeryczne	2
3.1	Jakość modelu ze względu na liczbę neuronów w warstwach ukrytych	2
3.2	Jakość modelu ze względu na liczbę warstw ukrytych	4
3.3	Wyniki i porównanie z modelem bazowym	5
4	Wnioski	6

1 Wstęp

Niniejszy dokument jest sprawozdaniem z 5 projektu z WSI. W jego ramach zaimplementowano i przetestowano perceptron wielowarstwowy do problemu regresji.

2 Opis implementowanych algorytmów

Zaimplementowano perceptron wielowarstwowy do regresji funkcji. Implementacja pozwala na podanie wielu przykładów treningowych w jednym wsadzie (ang. *batch*), które przetwarzane są jednocześnie. Każde przetworzenie wsadu jest nazywane epoką. Zastosowano propagację wsteczną za pomocą metody *batch gradient descent*, aktualizującą wagi sieci przy przetwarzaniu całego wsadu. Jako funkcji aktywacji użyto tangensa hiperbolicznego, a dane przed treningiem znormalizowano do przedziału $[-1, 1]$.


3 Eksperymenty numeryczne

W eksperymentach numerycznych współczynnik uczenia wynosi $\gamma = 0.01$. Rozmiar wsadu to 1000 przykładów treningowych. Liczba epok to 2000. Przeanalizowano liczbę neuronów w warstwach ukrytych oraz liczbę warstw ukrytych na jakość modelu. Oceną jakości jest wartość funkcji straty w ostatniej epoce. Rolę funkcji straty pełni błąd średniokwadratowy. W eksperymentach liczba neuronów w każdej warstwie ukrytej jest taka sama. Przykłady treningowe pochodzą z rozkładu jednostajnego z przedziału $[-10, 10]$ przy ziarnie generatora 42. Podany przedział stanowi dziedzinę funkcji aproksymowanej danej wzorem

$$f(x) = x^2 \cdot \sin(x) + 100 \cdot \sin(x) \cdot \cos(x).$$


3.1 Jakość modelu ze względu na liczbę neuronów w warstwach ukrytych

W tym eksperymencie zbadano wpływ liczby neuronów w czterech warstwach ukrytych. Na jednym z wykresów przedstawiono zmieniającą się jakość modelu w zależności od liczby neuronów w warstwach ukrytych mierzoną stratą w ostatniej epoce treningu, czyli w epoce o numerze 2000.



Rysunek 1: Wykres zależności funkcji straty od liczby neuronów w warstwach ukrytych.


Na kolejnym wykresie przedstawiono czas treningu w zależności od liczby neuronów w warstwach ukrytych.



Rysunek 2: Wykres zależności czasu od liczby neuronów w warstwach ukrytych.


3.2 Jakość modelu ze względu na liczbę warstw ukrytych

W tym eksperymencie ustalono liczbę neuronów w warstwie ukrytej na 50 i sprawdzono jak na jakość treningu wpływa zmiana liczby warstw ukrytych.



Rysunek 3: Wykres zależności wartości funkcji starty od liczby warstw ukrytych.


Zbadano również czas treningu sieci i przedstawiono na rysunku 4.



Rysunek 4: Wykres zależności czasu od liczby warstw ukrytych.


3.3 Wyniki i porównanie z modelem bazowym

Biorąc pod uwagę powyższe eksperymenty numeryczne liczba warstw ukrytych została ustalona na 5. Liczba neuronów w każdej warstwie ukrytej to 50. Przy tych parametrach oraz założeniach z początku sekcji *Eksperymenty numeryczne* narysowano wykres straty dla kolejnych epok.



Rysunek 5: Wykres zależności wartości funkcji straty od liczby epok.

Porównano wyniki perceptronu z modelem bazowym. Jako model bazowy wykorzystano model regresji wielomianowej ze stopniem wielomianu 35. Porównano błędy średniokwadratowe dla tych samych danych testowych oraz zestawiono wszystkie trzy wykresy - oryginalnej funkcji, aproksymowanej za pomocą perceptronu oraz aproksymowanej modelem regresji wielomianowej i pokazano na rysunku 6.



Rysunek 6: Zestawienie trzech wykresów funkcji.

Obliczono błąd średniokwadratowy oraz czasy treningu dla obu modeli i zestawiono w tabeli 1.

Model	Błąd średniokwadratowy	Czas [s]
perceptron wielowarstwowy	6.19	19.59
regresja wielomianowa	$1.48 \cdot 10^{-7}$	0.016

Tabela 1: Zestawienie danych o badanych modelach.

4 Wnioski

Z przeprowadzonych eksperymentów nasuwa się kilka wniosków. Większa liczba neuronów w warstwie w naszym przypadku oznaczała lepszą jakość modelu, ale zwiększała również czas treningu. Liczba warstw ukrytych nie może być za mała, ani za duża. Zbyt duża liczba warstw ukrytych może wymagać większej ilości epok w treningu. Większa liczba epok oraz większa liczba warstw ukrytych oznaczają dłuższy czas treningu. Wyznaczenie kompromisu między czasem, stratą, liczbą warstw oraz liczbą neuronów w warstwie jest niełatwym problemem i bywa czasochłonne. Sieci neuronowe to bez wątpienia potężne narzędzie, ale niestety kosztowne. Do problemu z tego ćwiczenia lepiej sprawdziła się regresja wielomianowa, która z małym błędem i bardzo krótkim czasem dobrze poradziła sobie z problemem regresji badanej funkcji.